

Performance Comparison of Classification Algorithms on the 3D Make-Moons Dataset

陈冠宇

学号：23377081

2026 年 4 月 5 日

摘要

本次作业基于给定程序生成三维 make-moons 数据集, 并比较了 Decision Tree、AdaBoost + Decision Tree 以及支持向量机 (SVM) 在该数据集上的分类性能。其中, SVM 分别选用了线性核、多项式核和径向基核 (RBF kernel) 三种不同的核函数。实验中生成训练集 1000 个样本和测试集 500 个样本, 训练集与测试集满足相同分布。通过 Accuracy、Precision、Recall、F1-score 和混淆矩阵对模型进行评价。实验结果表明, RBF 核 SVM 在该问题上取得了最优性能, AdaBoost + Decision Tree 次之, 单棵决策树和线性核 SVM 表现相对较弱。结果说明, 对于具有明显非线性边界的数据分布, 具备较强非线性建模能力的方法通常能够获得更好的分类效果。

1 引言

分类问题是机器学习中的核心任务之一, 其目标是根据给定的训练样本学习一个分类器, 使其能够对新的样本进行正确判别。分类模型的性能通常与数据分布特征密切相关: 当数据接近线性可分时, 简单模型即可获得较好结果; 而当数据本身呈现复杂的非线性结构时, 模型是否具备刻画非线性决策边界的能力就变得十分重要。

本次作业使用给定程序生成一个三维 make-moons 数据集。该数据集一共包含两类样本, 分别记为 C_0 和 C_1 。从几何形状上看, 两类样本具有明显的弯曲和交错结构, 因此是一个典型的非线性分类问题。实验中分别采用 Decision Tree、AdaBoost + Decision Tree 和 SVM 进行训练与测试, 并比较不同方法的分类性能。其中, SVM 选取了线性核、多项式核以及 RBF 核三种核函数, 以观察核函数选择对模型性能的影响。

2 数据集生成与实验设置

2.1 数据集生成

题目给出的程序通过构造三维 make-moons 数据集来生成样本。设函数中的参数 $n_samples$ 表示每一类样本的数量，则最终生成数据总数为 $2 \times n_samples$ 。因此，本实验中：

- 训练集设置为 $n_samples = 500$ ，共得到 1000 个样本，其中 $C0$ 类 500 个， $C1$ 类 500 个；
- 测试集设置为 $n_samples = 250$ ，共得到 500 个样本，其中 $C0$ 类 250 个， $C1$ 类 250 个。

训练集与测试集均由同一数据生成方式得到，并采用相同的噪声参数 $noise = 0.2$ ，因此可以认为测试集与训练集满足相同分布。

2.2 比较模型

本次实验比较以下模型：

1. 决策树 (Decision Tree)
2. AdaBoost + Decision Tree
3. SVM (Linear Kernel)
4. SVM (Polynomial Kernel)
5. SVM (RBF Kernel)

其中，AdaBoost 使用浅层决策树作为弱分类器；SVM 使用三种不同核函数，以体现线性核与非线性核在该问题上的差异。

2.3 评价指标

实验采用以下指标来评价模型性能：

- Accuracy (准确率)
- Precision (精确率)

- Recall (召回率)
- F1-score

此外，还结合混淆矩阵对各模型的分类情况进行分析。

3 方法简介

3.1 Decision Tree

决策树通过递归地对特征空间进行划分来完成分类任务。其优点是结构直观、易于解释，并且能够处理一定程度的非线性问题。然而，单棵决策树对数据噪声较为敏感，且容易出现过拟合或划分边界不够平滑的问题。

3.2 AdaBoost + Decision Tree

AdaBoost 是一种经典的集成学习方法，其基本思想是将多个弱分类器进行加权组合，逐步提高对难分类样本的关注程度，从而构造出一个更强的分类器。以浅层决策树作为基学习器时，AdaBoost 往往能够在保持一定非线性表达能力的同时，提高模型的泛化性能。

3.3 SVM

支持向量机 (SVM) 通过寻找最优分离超平面实现分类。当数据线性不可分时，可以借助核函数将数据映射到更高维空间，在高维空间中完成线性划分。本实验考虑三种核函数：

- 线性核 (Linear Kernel)
- 多项式核 (Polynomial Kernel)
- 径向基核 (RBF Kernel)

其中，RBF 核通过基于距离的非线性映射，通常能够较好地拟合具有复杂局部结构的数据分布。

4 实验结果

4.1 各模型测试结果

实验中得到的测试结果如表 1 所示。

表 1: 不同分类模型在测试集上的性能比较

模型	Accuracy	Precision	Recall	F1-score
Decision Tree	0.7120	0.9077	0.4720	0.6211
AdaBoost + Decision Tree	0.8560	0.8678	0.8400	0.8537
SVM (Linear Kernel)	0.6600	0.6600	0.6600	0.6600
SVM (Polynomial Kernel)	0.7680	0.7519	0.8000	0.7752
SVM (RBF Kernel)	0.9720	0.9683	0.9760	0.9721

从表中可以看出, RBF 核 SVM 在四项指标上都明显优于其他模型, 整体分类性能最好。AdaBoost + Decision Tree 的表现也较好, 说明集成学习相较于单棵决策树有显著提升。相比之下, 线性核 SVM 和单棵决策树在该数据集上的表现较弱。

4.2 混淆矩阵结果分析

为了更直观地说明各模型的分类情况, 下面结合混淆矩阵进行分析。

1. Decision Tree Decision Tree 的测试准确率为 0.7120。其混淆矩阵为:

$$\begin{bmatrix} 238 & 12 \\ 132 & 118 \end{bmatrix}$$

可以看出, 该模型对 $C0$ 类样本识别较好, 但对 $C1$ 类样本的召回率较低, 说明单棵树在面对该数据复杂边界时存在较明显的偏置。

2. AdaBoost + Decision Tree AdaBoost + Decision Tree 的测试准确率为 0.8560, 其混淆矩阵为:

$$\begin{bmatrix} 218 & 32 \\ 40 & 210 \end{bmatrix}$$

相比单棵决策树, AdaBoost 明显提高了对两类样本的整体识别能力, 说明集成多个弱分类器后, 模型可以更好地逼近数据的非线性边界。

3. SVM (Linear Kernel) 线性核 SVM 的测试准确率仅为 0.6600，其混淆矩阵为：

$$\begin{bmatrix} 165 & 85 \\ 85 & 165 \end{bmatrix}$$

从结果看，线性核 SVM 对两类样本的分类较为平均，但整体效果不理想。这是因为该数据集本身并不是线性可分的，单一超平面难以有效区分两类数据。

4. SVM (Polynomial Kernel) 多项式核 SVM 的测试准确率为 0.7680，其混淆矩阵为：

$$\begin{bmatrix} 184 & 66 \\ 50 & 200 \end{bmatrix}$$

相比线性核，多项式核具有更强的非线性表达能力，因此性能有所提升。但从结果来看，它仍然不能像 RBF 核一样灵活地刻画复杂的局部边界。

5. SVM (RBF Kernel) RBF 核 SVM 的测试准确率达到 0.9720，其混淆矩阵为：

$$\begin{bmatrix} 242 & 8 \\ 6 & 244 \end{bmatrix}$$

可以看出，该模型几乎能够正确区分两类样本，在 Precision、Recall 和 F1-score 上都达到最高水平，说明其对该数据分布具有非常强的适应能力。

4.3 结果图

下图由 4 个子图组成，分别展示 Accuracy、Precision、Recall 和 F1-score 四个指标下不同模型的对比柱状图。




图 1: 不同分类模型在各评价指标下的性能对比图

5 结果分析与讨论

从整体实验结果来看, 不同分类方法在该 3D make-moons 数据集上的性能差异较大, 这与数据本身的非线性结构密切相关。

首先, 线性核 SVM 的表现最差之一。其主要原因在于线性核 SVM 只能在原始特征空间中寻找一个线性分离超平面, 而该数据集中的两类样本呈现明显的弯曲和交错分布, 因此很难通过单一平面将它们分开。

其次, 单棵 Decision Tree 的表现优于线性核 SVM, 但仍然有限。虽然决策树具有一定的非线性建模能力, 可以通过递归划分特征空间构造复杂边界, 但它的划分方式本质上是分段且偏轴对齐的, 不太适合描述类似双月牙这样连续而平滑的弯曲边界。此外, 单棵决策树对噪声较为敏感, 因此容易造成泛化能力不足。

AdaBoost + Decision Tree 的效果明显优于单棵决策树。这说明集成学习能够有效提升模型性能。通过不断叠加多个弱分类器, AdaBoost 可以逐步修正前面分类错误的样本, 从而得到更强的分类边界。对于该问题, Boosting 在一定程度上弥补了单棵树表达能力有限的问题, 因此取得了较好的结果。

SVM 中, 多项式核的表现介于线性核和 RBF 核之间。多项式核能够提供一定程

度的非线性映射，因此相较线性核有明显提升。但由于双月牙数据的边界具有比较复杂的局部弯曲特征，多项式核这种相对整体性的映射方式仍然不如 RBF 核灵活。

RBF 核 SVM 的表现最好，这也是本实验最重要的结论。RBF 核基于样本之间的距离构造非线性映射，能够较好地捕捉数据分布中的局部结构，因此非常适合处理 make-moons 这种具有明显非线性边界的数据。实验结果显示，RBF 核 SVM 在测试集上取得了 0.9720 的准确率，同时在 Precision、Recall 和 F1-score 上也都达到最高，说明其不仅分类准确，而且对两类样本都具有较强的识别能力。

6 结论

本次实验基于 3D make-moons 数据集，比较了 Decision Tree、AdaBoost + Decision Tree 以及采用三种不同核函数的 SVM 的分类性能。实验结果表明：

- 线性核 SVM 由于无法有效刻画非线性边界，性能较弱；
- 单棵决策树具备一定的非线性分类能力，但受限于其划分方式和泛化能力，整体表现一般；
- AdaBoost + Decision Tree 通过集成学习显著提升了分类性能；
- RBF 核 SVM 在该数据集上取得了最佳结果，说明其最适合处理此类具有复杂非线性结构的数据。

因此，对于类似 3D make-moons 这样明显非线性可分的问题，具备较强非线性建模能力、并且能够较好利用局部结构信息的方法通常更具优势，其中 RBF 核 SVM 是本实验中表现最好的模型。

参考文献

- [1] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [2] Trevor Hastie, Robert Tibshirani, Jerome Friedman. *The Elements of Statistical Learning*. Springer, 2009.
- [3] V. N. Vapnik. *The Nature of Statistical Learning Theory*. Springer, 1995.