

Air Quality Prediction Based on LSTM

陈冠宇

学号：23377081

2026 年 4 月 27 日

摘要

本次作业基于空气质量时间序列数据集，使用长短期记忆网络（Long Short-Term Memory, LSTM）完成多变量污染浓度预测任务。数据集中包含 PM2.5 浓度、露点、温度、气压、风向、风速、累计降雪小时数和累计降雨小时数等变量。实验目标是在给定过去若干小时空气质量和天气条件的前提下，预测下一小时的 PM2.5 污染浓度。

实验中采用过去 24 小时的多变量观测序列作为 LSTM 输入，并预测下一小时的污染浓度。由于测试文件实际上对应原始时间序列末尾的一段数据，为避免数据泄漏，本文在训练阶段从原始训练文件中删除与测试集重合的最后 346 条记录。数据预处理阶段，对风向变量进行 one-hot 编码，对数值特征进行标准化，并利用滑动窗口构造时间序列样本。模型采用两层 LSTM 提取时间依赖特征，并通过全连接回归层输出污染浓度预测值。

实验结果表明，LSTM 能够较好地拟合空气污染浓度随时间变化的趋势，在测试集上取得了 $MAE = 14.7678$ 、 $RMSE = 26.1509$ 、 $R^2 = 0.9290$ 的结果，说明模型对多变量空气质量时间序列具有较好的预测能力。

1 引言

空气污染预测是时间序列建模中的重要应用问题之一。PM2.5 浓度不仅与当前污染水平有关，还与气象条件、风速、气压、降水以及前一段时间的污染变化趋势密切相关。因此，相比只使用当前时刻特征进行静态回归，利用历史序列信息往往能够获得更准确的预测结果。

传统机器学习模型通常将每一条样本视为相互独立的数据点，难以直接建模时间上的长期依赖关系。而 LSTM 是循环神经网络（Recurrent Neural Network, RNN）的一种改进结构，通过引入输入门、遗忘门和输出门，可以在一定程度上缓解普通 RNN 中的梯度消失问题，并更好地捕捉时间序列中的长期依赖。

本次实验使用 Kaggle 空气质量数据集，构造多变量时间序列预测任务。具体而言，模型输入为过去 24 小时的污染浓度和天气特征，输出为下一小时的 PM2.5 浓度。本

文将从数据预处理、滑动窗口构造、LSTM 模型结构、训练过程和实验结果几个方面展开说明。

2 数据集与实验设置

2.1 数据集介绍

本实验使用的空气质量数据集记录了多个年份内每小时的天气与污染水平。原始数据包括以下变量：

- pollution: PM2.5 污染浓度;
- dew: 露点;
- temp: 温度;
- press: 气压;
- wnd_dir: 风向;
- wnd_spd: 累计风速;
- snow: 累计降雪小时数;
- rain: 累计降雨小时数。

本次实验使用两份数据文件：原始大表 `LSTM-Multivariate_pollution.csv` 和测试文件 `pollution_test_data1.csv`。程序运行时得到的原始大表大小为 (43800, 9)，测试集大小为 (346, 8)。

经过检查发现，测试文件中的 346 条数据实际上对应原始大表最后 346 条记录。如果直接使用完整大表训练模型，再使用测试文件进行测试，则测试数据已经在训练过程中被模型见过，会造成严重的数据泄漏。因此，本文在训练阶段删除原始大表最后 346 条记录，仅使用测试集之前的历史数据训练模型。

最终数据划分方式如下：

- 原始大表样本数：43800;
- 测试集样本数：346;
- 去除测试段后的真实训练集样本数：43454。

2.2 时间顺序与滑动窗口构造

由于本任务是时间序列预测问题，因此数据的时间顺序非常重要。训练集中包含 `date` 字段，本文首先利用该字段对训练数据按时间排序，然后删除 `date` 字段。删除 `date` 并不意味着忽略时间信息，而是不直接将日期字符串作为模型输入。LSTM 使用的时间信息主要来自样本在时间序列中的排列顺序。

本实验使用滑动窗口方法构造监督学习样本。设滑动窗口长度为 $L = 24$ ，则对于目标时刻 t ，输入序列为：

$$X_{t-L}, X_{t-L+1}, \dots, X_{t-1}$$

对应标签为：

$$y_t$$

即模型使用过去 24 小时的多变量观测值预测下一小时的污染浓度。

构造后的数据规模如下：

表 1: 滑动窗口构造后的数据规模

数据集	输入序列维度	标签维度
训练集	(39087, 24, 11)	(39087,)
验证集	(4343, 24, 11)	(4343,)
测试集	(346, 24, 11)	(346,)

其中，输入序列维度中的 24 表示每个样本包含过去 24 小时的历史信息，11 表示每个时间步包含 11 个输入特征。

2.3 数据预处理

本实验的数据预处理主要包括以下步骤：

1. 删除训练集中的 `date` 字段，但在删除前使用该字段保证训练样本按时间顺序排列；
2. 对数值变量进行类型转换，并使用前向填充和后向填充处理缺失值；
3. 将风向变量 `wnd_dir` 进行 one-hot 编码；
4. 将测试集特征列重新对齐到训练集特征列，保证训练集和测试集输入维度一致；
5. 仅使用训练集拟合标准化器，然后对训练集、验证集和测试集进行标准化，避免测试集信息泄漏。

经过 one-hot 编码后，最终输入特征包括：

`pollution, dew, temp, press, wnd_spd, snow, rain, wnd_dir_NE, wnd_dir_NW, wnd_dir_SE, wnd_dir`

共 11 个特征。

需要注意的是，`pollution` 本身也作为输入特征之一。这是因为预测下一小时污染浓度时，过去若干小时的污染浓度是非常重要的历史信息。模型并不是使用当前时刻的标签预测自身，而是使用过去 24 小时的污染和天气序列预测下一小时的污染值。

3 方法简介

3.1 LSTM 模型

LSTM 是一种特殊的循环神经网络结构，适合处理具有时间依赖关系的序列数据。普通 RNN 在处理长序列时容易出现梯度消失或梯度爆炸问题，导致模型难以学习长期依赖。LSTM 通过门控机制控制信息的遗忘、写入和输出，从而能够更稳定地建模时间序列中的长期关系。

LSTM 的核心思想是维护一个细胞状态 (cell state)，并通过遗忘门、输入门和输出门决定历史信息如何在时间上传递。对于空气质量预测任务而言，污染浓度不仅取决于当前气象条件，也受到过去若干小时污染积累和扩散过程的影响，因此 LSTM 适合用于该任务。

3.2 模型结构

本实验采用的模型结构如下：

- 输入维度：11；
- 时间窗口长度：24；
- LSTM 层数：2；
- LSTM 隐藏层维度：64；
- Dropout：0.2；
- 回归头：Linear(64, 32) + ReLU + Dropout + Linear(32, 1)。

模型结构可以表示为：

$$\hat{y}_t = f_{\theta}(X_{t-24}, X_{t-23}, \dots, X_{t-1})$$

其中， f_{θ} 表示 LSTM 及其后续全连接回归层， $\hat{y}_t$ 表示模型预测的第 t 小时污染浓度。

具体模型输出如下：

```
LSTMRegressor(
  (lstm): LSTM(11, 64, num_layers=2, batch_first=True, dropout=0.2)
  (regressor): Sequential(
    (0): Linear(in_features=64, out_features=32, bias=True)
    (1): ReLU()
    (2): Dropout(p=0.2, inplace=False)
    (3): Linear(in_features=32, out_features=1, bias=True)
  )
)
```

3.3 训练设置

实验中采用均方误差 (Mean Squared Error, MSE) 作为训练损失函数:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

优化器使用 Adam, 学习率设置为 10^{-3} , batch size 设置为 64。为了缓解 LSTM 训练中可能出现的梯度爆炸问题, 训练过程中采用梯度裁剪, 将梯度范数限制在 5.0 以内。

训练集中的最后 10% 序列作为验证集, 用于监控模型泛化性能。若验证集损失长期不再下降, 则提前停止训练, 以减少过拟合风险。

4 实验结果

4.1 训练过程

模型原计划训练 50 个 epoch, 但由于验证集损失在后续训练中长期没有明显提升, 最终在第 17 个 epoch 触发 early stopping。训练过程中部分结果如下:

表 2: 部分训练过程中的训练损失与验证损失

Epoch	Train Loss	Validation Loss
1	0.181612	0.059732
2	0.115012	0.052051
3	0.110279	0.050398
4	0.107926	0.049556
7	0.107089	0.049419
9	0.101819	0.048564
13	0.101126	0.051189
16	0.098260	0.053048
17	0.097903	0.051140

从表中可以看出，训练损失整体呈下降趋势，说明模型逐渐学习到了数据中的时间序列规律。验证集损失在前几个 epoch 内明显下降，并在第 9 个 epoch 左右达到较低水平，随后出现小幅波动。这说明模型继续训练时对训练集拟合有所增强，但验证集性能没有继续稳定提升，因此 early stopping 是合理的。

4.2 测试集评价指标

在测试集上，模型最终取得如下结果：

表 3: LSTM 模型在测试集上的预测性能

评价指标	数值
Test MSE Loss	0.080443
MAE	14.7678
RMSE	26.1509
R^2	0.9290

其中，MAE、RMSE 和 R^2 的定义如下：

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

从结果来看，模型在测试集上取得了 $R^2 = 0.9290$ ，说明预测结果能够解释测试集中大部分污染浓度变化。同时，MAE 为 14.7678，表示模型预测值与真实 PM2.5 浓度之间的平均绝对误差约为 14.77。考虑到污染浓度本身在不同时间段内存在较大波动，该结果说明 LSTM 对整体变化趋势具有较好的拟合能力。

4.3 训练损失曲线

图 1 展示了训练集和验证集损失随 epoch 变化的情况。




图 1: LSTM 训练集与验证集损失曲线

从图中可以观察到，训练损失在初始阶段下降较快，之后逐渐趋于平稳。验证损失在前期同样明显下降，但后期出现一定波动，没有持续降低。这说明模型已经学习到主要的时间序列模式，继续训练可能带来轻微过拟合，因此使用 early stopping 可以避免模型在训练集上过度拟合。

4.4 预测结果曲线

图 2 展示了测试集上真实 PM2.5 浓度与模型预测值的对比曲线。




图 2: 测试集上真实值与预测值对比曲线

从预测曲线可以看出，LSTM 模型整体能够较好地跟随 PM2.5 浓度的变化趋势。在大多数时间段内，预测曲线与真实曲线走势接近，说明模型能够利用过去 24 小时的污染和天气信息对未来污染水平进行有效预测。

不过,在部分污染浓度快速上升或快速下降的时刻,预测曲线仍然可能存在一定滞后或低估现象。这是时间序列预测中较常见的问题,原因可能在于突发污染变化受到外部因素影响,而这些因素并未完全包含在当前数据特征中。

5 结果分析与讨论

从整体实验结果来看,LSTM 在该空气质量预测任务上取得了较好的效果。其主要原因在于 PM2.5 浓度具有明显的时间相关性,当前时刻的污染水平往往与过去若干小时的污染水平、风速、气压和降水情况有关。LSTM 通过对过去 24 小时多变量序列进行建模,能够捕捉污染浓度随时间变化的动态规律。

首先,滑动窗口的设计使得原本的时间序列数据被转换为适合监督学习的输入输出形式。每个输入样本并不是单独的一行数据,而是连续 24 小时的观测序列。因此,模型能够看到污染和气象变量在一段时间内的变化趋势,而不是只根据单一时刻的静态特征进行预测。

其次,将历史污染浓度作为输入特征是合理的。PM2.5 浓度通常存在较强的自相关性,即过去几个小时的污染水平对下一小时污染水平具有重要影响。实验结果中较高的 R^2 也说明模型较好地利用了这种时间相关性。

再次,本文在实验中特别注意避免数据泄漏。由于测试文件实际上来自原始大表末尾,如果不删除原始大表中与测试集重合的部分,模型会在训练阶段提前见到测试样本,从而导致测试结果虚高。本文在训练前删除最后 346 条记录,仅使用测试段之前的历史数据训练模型,因此实验结果更符合真实预测场景。

从不足来看,当前模型仍然存在两个方面的限制。第一,测试集没有日期字段,因此无法进一步构造小时、月份、星期等周期性时间特征。如果能够使用这些时间特征,模型可能更好地捕捉空气污染的日周期和季节性变化。第二,数据中只包含有限的气象变量,而真实污染变化还可能受到交通流量、工业排放、节假日、城市活动等外部因素影响,这些未观测因素可能导致模型在突发变化时预测不够准确。

6 结论

本次实验基于空气质量多变量时间序列数据集,使用 LSTM 模型完成下一小时 PM2.5 浓度预测任务。实验中使用过去 24 小时的污染浓度和天气变量作为输入,预测下一小时污染浓度。经过数据清洗、one-hot 编码、标准化和滑动窗口构造后,最终输入序列维度为 (24, 11)。

实验结果表明,LSTM 能够有效学习空气质量数据中的时间依赖关系,在测试集上取得了 $MAE = 14.7678$ 、 $RMSE = 26.1509$ 、 $R^2 = 0.9290$ 的结果。预测曲线显示,模型整体能够较好地跟随真实污染浓度变化趋势,说明 LSTM 适合用于该类多变量时间序列预测任务。

此外,本实验也说明,在时间序列任务中,合理的数据划分非常重要。由于测试集

来自原始大表的最后一段，若直接使用完整大表训练模型，会造成数据泄漏。本文通过删除训练大表中与测试集重合的最后 346 条记录，保证测试集只用于最终评估，从而提高了实验结果的可信度。

未来可以进一步尝试引入更多时间周期特征，或者比较 GRU、Transformer、Temporal Convolutional Network 等不同时间序列模型，以进一步提升空气污染预测效果。

参考文献

- [1] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [2] Sepp Hochreiter and Jürgen Schmidhuber. Long Short-Term Memory. *Neural Computation*, 9(8):1735–1780, 1997.
- [3] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016.
- [4] Kaggle. LSTM Datasets: Multivariate and Univariate Air Pollution Dataset. <https://www.kaggle.com/datasets/rupekroy/lstm-datasets-multivariate-univariate/data>.