

Attention Is All You Need 小型复现与消融实验

陈冠宇

学号：23377081

2026 年 5 月 14 日

摘要

本次作业围绕 Vaswani 等人在 2017 年提出的经典论文《Attention Is All You Need》展开。原论文在 WMT 2014 英德和英法机器翻译任务上训练了大规模 Transformer 模型，但该复现需要较大的语料、较长训练时间和多卡计算资源。为了在课程作业环境中完成可控复现，本文使用小型合成序列转导任务替代原始机器翻译数据：输入为随机 token 序列，输出为该序列的反序结果。该任务虽然规模较小，但保留了位置建模、序列重排、长距离 token 搬运等 Transformer 的核心能力要求。

实验中实现了一个小型 encoder-decoder Transformer，包括 token embedding、正弦位置编码、多头 scaled dot-product attention、残差连接、LayerNorm 和前馈网络等原论文核心模块。在此基础上，本文完成了两个消融实验。第一，研究 Q、K、V 的必要性，将标准注意力中的 K 和 V 合并为同一个投影，构造 QK-only 变体。第二，研究加入位置编码后的 CNN 能否替代自注意力机制，构造带正弦位置编码的一维卷积网络并与 Transformer 进行比较。

实验结果表明，在长度为 8 的反序任务上，2 层标准 Transformer 最终取得 Token Accuracy = 0.9880、Sequence Accuracy = 0.9051；2 层 QK-only 模型取得 Token Accuracy = 0.9766、Sequence Accuracy = 0.8234；2 层 CNN 仅取得 Token Accuracy = 0.5168、Sequence Accuracy = 0.0000；当 CNN 加深到 6 层后，在短序列上可以达到接近满分的结果。这说明独立的 V 投影有助于将“寻址”和“内容传递”解耦；位置编码可以提供顺序信息，但不能单独替代自注意力的全局动态连接能力。CNN 也可以完成短序列重排任务，但通常需要更深层数或更大感受野。

1 引言

序列建模是自然语言处理中的核心问题。早期神经机器翻译模型主要依赖循环神经网络或卷积神经网络。循环网络按照时间步顺序处理序列，适合表达序列递推关系，但

难以并行，并且在长距离依赖场景下容易出现信息衰减。卷积网络可以并行计算，但每层卷积通常只能处理局部窗口，若要建立远距离位置之间的联系，需要堆叠更多层。

Transformer 的提出改变了这一范式。Vaswani 等人提出完全基于注意力机制的 encoder-decoder 模型，用 self-attention 替代循环结构和卷积结构。self-attention 允许序列中任意两个位置在同一层中直接交互，因此能够更直接地建模长距离依赖，同时也更适合 GPU 并行训练。

本次实验的目标并不是复现原论文的完整 WMT 翻译结果，而是在有限服务器资源下复现 Transformer 的关键结构，并通过消融实验理解模块的必要性。本文选择两个问题进行研究：其一，如果将 K 和 V 合并，注意力机制的表达能力会受到怎样的影响；其二，如果保留位置编码但用 CNN 替代 self-attention，模型在序列重排任务上的表现如何。

2 数据集与实验设置

2.1 小型复现任务

原论文使用 WMT 2014 英德和英法机器翻译数据集。完整复现需要大规模双语语料、分词处理、较长训练时间和多卡训练资源。为了使实验能够在单卡或双卡服务器上快速完成，本文采用合成序列转导任务作为小型复现任务。

默认任务为 reverse。模型输入为长度固定的 token 序列：

$$x = [x_1, x_2, \dots, x_L]$$

目标输出为输入序列的反序：

$$y = [x_L, x_{L-1}, \dots, x_1]$$

本任务能够检验模型是否理解位置信息，并且能否把源序列中远距离位置的 token 搬运到目标位置。对于 encoder-decoder Transformer 来说，decoder 的每个位置需要通过 cross-attention 找到 encoder 中对应的源位置，因此该任务适合观察 Q、K、V 和 self-attention 的作用。

2.2 数据生成方式

训练数据在每个 batch 中动态随机生成，不使用外部下载数据集。具体实现位于 `transformer_lab/data.py`。程序从 `[2, vocab_size)` 中均匀采样 token，保留 0 作为 PAD，1 作为 BOS。对于每个随机输入序列，标签由反序操作直接构造。

默认参数如下：

表 1: 数据生成与训练默认参数

项目	数值
任务	reverse
序列长度	8
词表大小	32
batch size	128
训练步数	1000
验证间隔	200 steps
随机种子	42

由于数据是动态合成的，训练集和验证集并不是固定文件，而是在每次训练和评估时重新采样。这样可以避免模型记忆固定训练样本，更关注模型是否真正学会反序规则。

2.3 评价指标

实验使用交叉熵损失训练模型，评价指标包括 token 级准确率和 sequence 级准确率。

Token Accuracy 统计所有位置上预测 token 是否正确。Sequence Accuracy 要求整条序列的所有位置都预测正确，因此更加严格。在反序任务中，sequence accuracy 能更直接反映模型是否完整掌握了输入输出映射规则。

3 方法简介

3.1 小型 Transformer 结构

本文实现的 Transformer 采用 encoder-decoder 结构，保留原论文的核心模块：

1. token embedding，并乘以 $\sqrt{d_{\text{model}}}$ ；
2. 正弦位置编码；
3. 多头 scaled dot-product attention；
4. 残差连接和 LayerNorm；
5. position-wise feed-forward network；
6. decoder 中的 causal self-attention 和 encoder-decoder cross-attention。

标准注意力计算形式为：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V$$

其中 Q 表示当前位置的查询需求， K 表示每个位置用于匹配的键， V 表示被注意力选中后传递的内容。多头注意力将表示空间划分为多个子空间，使模型可以从不同角度建立 token 之间的关系。

3.2 Q、K、V 消融实验

为了研究 Q 、 K 、 V 的必要性，本文构造 QK-only 变体。该变体保留 Q 和 K 的注意力权重计算，但将 V 与 K 合并，即使用同一个投影作为 key 和 value。

这种设计的含义是：模型仍然能够计算“当前位置应该关注哪个源位置”，但被传递的信息必须与匹配用的 key 表示相同。相比标准注意力，它失去了“寻址表示”和“内容表示”的解耦能力。本文通过比较标准 Transformer 与 QK-only 的训练曲线和最终准确率，观察独立 V 投影的作用。

3.3 位置编码 + CNN 对照实验

第二个消融实验关注位置编码和 self-attention 的关系。本文构造 CNNSequence-Model：它使用与 Transformer 相同的 token embedding 和正弦位置编码，但将 self-attention 层替换为一维卷积残差块。

CNN 的优势是局部模式提取和并行计算，但卷积核大小限制了单层感受野。若要让较远位置的信息相互影响，需要堆叠更多卷积层。通过比较 2 层 CNN、6 层 CNN 和 2 层 Transformer，可以区分位置编码本身与全局动态注意力机制的作用。

3.4 训练设置

实验使用 PyTorch 实现，运行环境为 minimind_v conda 环境，PyTorch 版本为 2.11.0+cu130，CUDA 可用。主要训练设置如下：

表 2: 主要训练设置

项目	数值
优化器	Adam
学习率	0.001
dropout	0.0
梯度裁剪	1.0
Transformer 层数	2
注意力头数	4
d_{model}	128
d_{ff}	256
CNN kernel size	5

运行命令如下:

```
/home/buaachenguanyu/anaconda3/envs/minimind_v/bin/python run_experiments.py --
models transformer qk_only cnn --task reverse --seq-len 8 --steps 1000 --
dropout 0.0 --lr 0.001 --device cuda:0 --output-dir runs_final
```

补充 6 层 CNN 的命令如下:

```
/home/buaachenguanyu/anaconda3/envs/minimind_v/bin/python train.py --model cnn
--task reverse --seq-len 8 --layers 6 --steps 1000 --dropout 0.0 --lr 0.001
--device cuda:0 --output-dir runs_final
```

4 实验结果

4.1 小型 Transformer 复现结果

表 3 展示了本次实验的最终结果。

表 3: 不同模型在反序任务上的最终结果

模型	层数	Token Accuracy	Sequence Accuracy
Transformer	2	0.9880	0.9051
QK-only	2	0.9766	0.8234
CNN	2	0.5168	0.0000
CNN	6	1.0000	1.0000

从结果可以看出，小型 Transformer 能够较好地完成反序任务，在 1000 步训练后达到 0.9880 的 token accuracy 和 0.9051 的 sequence accuracy。这说明所实现的 embedding、位置编码、多头注意力、残差连接和 encoder-decoder cross-attention 可以有效学习序列重排规则。




图 1: 小型复现 Token Accuracy

4.2 Q、K、V 消融结果

图 2 展示了标准 Transformer 与 QK-only 变体的 sequence accuracy 曲线。标准 Transformer 在整个训练过程中整体优于 QK-only。最终标准 Transformer 的 sequence accuracy 为 0.9051，而 QK-only 为 0.8234。




图 2: QKV 消融 Sequence Accuracy

该结果说明，即使 K 和 V 合并后模型仍具有一定学习能力，但表达能力有所下降。标准注意力中，K 更偏向“如何被匹配”，V 更偏向“传递什么内容”。反序任务需要模型先找到源序列中的对应位置，再把该位置的 token 信息传递给 decoder。如果 K 和 V 共用同一表示，模型在匹配和内容搬运之间需要折中，因此训练速度和最终准确率都会受到影响。

4.3 位置编码 + CNN 对照结果

图 3 展示了 Transformer、2 层 CNN 和 6 层 CNN 的 sequence accuracy 曲线。2 层 CNN 在 1000 步后 sequence accuracy 仍为 0，说明仅加入位置编码并不能保证浅层 CNN 完成全局序列重排任务。




图 3: CNN 对照 Sequence Accuracy

但当 CNN 加深到 6 层后, 模型可以在长度为 8 的短序列上达到 1.0000 的 sequence accuracy。这说明 CNN 并不是不能解决该任务, 而是需要通过更多层数扩大感受野, 并通过多层非线性逐步传播远距离信息。

图 4 进一步展示了四种模型最终 sequence accuracy 的柱状对比。




图 4: 最终 Sequence Accuracy

5 结果分析与讨论

本实验的第一个重要结论是，Transformer 的优势并不只来自位置编码，而来自位置编码与注意力机制的结合。正弦位置编码使模型能够区分不同位置，但真正完成远距离 token 搬运的是 self-attention 和 cross-attention。对于反序任务，目标位置需要从源序列中找到相反方向的对应位置，这种全局匹配非常适合注意力机制。

第二个结论是，Q、K、V 的独立设计具有实际意义。Q 和 K 共同决定注意力权重，可以理解为“查找”和“被查找”的匹配过程；V 则决定被选中位置向外提供什么信息。若将 K 和 V 合并，模型仍然可以通过注意力矩阵建立位置关系，但内容通道受到限制。实验中 QK-only 的最终准确率低于标准 Transformer，说明这种解耦确实提升了表达能力。

第三个结论是，CNN 加位置编码可以作为一种可行的序列建模方法，但它与 Transformer 的信息流动方式不同。2 层 CNN 的失败说明，位置编码只告诉模型“在哪里”，并不自动提供“任意位置如何直接交互”的能力。6 层 CNN 的成功则说明，在短序列任务中，只要感受野足够大，CNN 也能学习反序规则。因此，更准确的说法不是 CNN 不能做序列重排，而是 CNN 通常需要通过深度或大卷积核弥补固定局部连接的限制。

本实验也存在一些限制。首先，合成反序任务比真实机器翻译简单，不涉及自然语言中的语义、句法和多义性。其次，动态生成数据虽然适合快速验证结构能力，但不能完全替代真实语料上的泛化评估。最后，本实验只使用单个随机种子，正式研究中应使用多个随机种子重复实验，并报告均值和方差。

6 结论

本文完成了《Attention Is All You Need》的小型复现和两个消融实验。由于原论文 WMT 机器翻译复现资源需求较高，本文采用合成反序序列转导任务作为轻量替代，并实现了包含 encoder、decoder、多头注意力、位置编码、残差连接和前馈网络的小型 Transformer。

实验结果表明，标准 Transformer 能够稳定学习反序规则，并在 1000 步训练后取得较高准确率。QK-only 消融实验表明，将 K 和 V 合并会降低模型表现，说明独立的 value 通道对于内容传递具有重要作用。CNN 对照实验表明，位置编码本身不能替代 self-attention；浅层 CNN 难以完成全局序列重排，但加深 CNN 后可以在短序列任务上达到很好效果。

总体而言，本实验从可运行的小型复现出发，验证了 Transformer 中若干核心模块的必要性。独立 Q/K/V 表示使注意力同时具备匹配和内容传递能力；位置编码提供顺序信息；self-attention 提供全局动态连接。这些模块共同构成了 Transformer 在序列建模任务中表现优异的关键原因。

参考文献

- [1] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention Is All You Need. *Advances in Neural Information Processing Systems*, 2017.
- [2] Dzmitry Bahdanau, Kyunghyun Cho, and Yoshua Bengio. Neural Machine Translation by Jointly Learning to Align and Translate. *International Conference on Learning Representations*, 2015.
- [3] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016.
- [4] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.